

1) Onyx là gì?

Onyx là một nền tảng AI cho doanh nghiệp, chứ không chỉ là một chatbot. Onyx mô tả nó là “entry point to Generative AI” cho cả team: một nơi để dùng LLM, tìm tài liệu nội bộ, duyệt web, tạo agent, và kết nối vào ứng dụng công ty. Ở góc enterprise search, họ cũng định vị rất rõ là công cụ để tìm thông tin trên toàn bộ dữ liệu công ty.

Onyx **không phải kiểu “gom nhiều model vào một ô chat”**. Bản chất của nó là một **lớp AI workplace** gồm chat, search, agents, actions, code interpreter, web search, deep research, connectors tới 40+ nguồn dữ liệu, và có thể chạy theo kiểu **Onyx Cloud, self-host open-source, hoặc self-host enterprise**. Repo chính thức còn nhấn mạnh là nó chạy được trong môi trường **air-gapped hoàn toàn**.

Onyx đang cố trở thành **hệ AI nội bộ của cả công ty** — nơi vừa hỏi đáp, vừa tra cứu tri thức, vừa gọi công cụ, vừa gắn với quyền truy cập và hạ tầng doanh nghiệp.

2) End-user làm được gì trong Onyx?

- Onyx có cả giao diện **chat** lẫn giao diện **search**; search hợp hơn khi mục tiêu là tìm tài liệu hoặc nguồn gốc thông tin, còn chat hợp hơn khi muốn hỏi đáp trực tiếp. Khi cần dữ liệu mới hoặc câu hỏi ngách, Onyx có thể bật **web search** và còn ghép web với knowledge nội bộ trong cùng câu trả lời. Ngoài ra còn có **Deep Research** cho các câu hỏi khó; docs nói chế độ này có thể chạy nhiều vòng suy nghĩ, nghiên cứu và hành động, mất tới vài phút và có thể tốn hơn **10 lần** chi phí token so với suy luận bình thường.

- Có thể dùng **Agents**. Trong Onyx, agent là tổ hợp của **instructions + knowledge + actions**; chuyên cho một việc cụ thể như onboarding, helpdesk, engineer copilot hay legal reviewer. Agent có thể dùng cá nhân hoặc chia sẻ cho user và group khác trong workspace.

- Về công cụ, Onyx có 4 action built-in:

- **Internal Search** : Đây là công cụ để Onyx tìm trong dữ liệu nội bộ đã được index của công ty bạn.
- **Web Search**: Đây là công cụ để Onyx tìm thông tin trên Internet khi câu hỏi cần dữ liệu mới
- **Code Interpreter**: Đây là công cụ cho phép Onyx tự viết và chạy Python code trong môi trường sandbox an toàn. Docs mô tả nó là một Python runtime an toàn, cho phép làm tính toán phức tạp, phân tích dữ liệu trên file upload, tạo biểu đồ, và tạo hoặc chỉnh sửa tài liệu. Nó có sẵn trong mọi deployment và không cần cấu hình thêm.
- **Image Generation**: Đây là công cụ để Onyx **tạo ảnh từ prompt text**. Docs mô tả tính năng này cho phép user tạo **PNG images** theo prompt, hiển thị ngay trong chat và tải xuống dễ dàng. Việc cấu hình model tạo ảnh nằm ở Admin Panel, và sau khi cấu hình xong thì Image Generation có thể được gọi từ bất kỳ Agent hoặc AI model nào trong Onyx.

Commented [HN1]: Onyx Cloud là bản Onyx do chính Onyx host và vận hành. Không phải tự dựng server, tự cài Docker hay tự lo update hạ tầng. Chỉ cần đăng ký và dùng.

Self-host open-source nghĩa là tự cài và tự chạy Onyx trên hạ tầng của mình, dùng bản mã nguồn mở của Onyx. phù hợp khi bạn muốn tự giữ dữ liệu, tự kiểm soát môi trường chạy, hoặc không muốn phụ thuộc hoàn toàn vào cloud của vendor. Repo GitHub của họ cũng mô tả Onyx là self-hostable và là một open-source AI platform. Self-host enterprise cũng là tự host trên hạ tầng, nhưng thay vì chỉ dùng bản open-source cơ bản thì dùng Enterprise Edition của Onyx. Bản này mở khóa thêm các tính năng thiên về doanh nghiệp lớn như RBAC, tự động sync quyền truy cập, advanced knowledge curation, cùng các tính năng về security, user management, site customization. Họ cũng nói bản này hợp với large teams with strict data requirements.

Commented [HN2]: Air-gapped nghĩa là hệ thống chạy trong môi trường tách biệt hoàn toàn khỏi Internet hoặc gần như không có kết nối ra ngoài. Nhưng khi đó phải tự host LLM của để Onyx kết nối vào, vì không thể gọi model ngoài Internet được.

- Ngoài web app, Onyx còn có **desktop app** cho Windows, macOS, Linux; **Chrome extension** để mang Onyx vào mọi tab; **Discord bot** để chat với agent và search knowledge base ngay trong Discord; và **MCP Server** để các client như Claude Desktop, Claude Code, Cursor hay Windsurf truy cập vào knowledge base của Onyx. Nếu muốn nhúng vào app khác, Onyx còn có API keys và PATs để gọi API như một user hoặc như một app riêng.

3) Phần hỗ trợ doanh nghiệp của Onyx

Onyx có **Admin Panel** riêng để quản lý models, connectors, actions, agents, users, groups, analytics, billing và các cấu hình nâng cao. Docs admin mô tả khá rõ: đây là nơi quản trị toàn bộ workspace, không chỉ là nơi đổi prompt hay thêm API key.

Phần mạnh nhất của Onyx ở doanh nghiệp là **connectors + quyền truy cập**. **Connectors** của Onyx sync dữ liệu thường xuyên từ nguồn gốc và có thể cấu hình là **Private**, **Public** hoặc **Auto Sync Permissions**. Với Auto Sync Permissions, Onyx sẽ giữ Access Control List từ nguồn và chỉ cho user thấy đúng dữ liệu họ được phép thấy; nhưng docs cũng cảnh báo rất thẳng thắn là nếu bạn cấu hình connector theo kiểu Public mà nguồn gốc chứa private data, toàn bộ user Onyx có thể nhìn thấy dữ liệu đó. Những connector hỗ trợ permission syncing gồm Confluence, Jira, Google Drive, Gmail, Slack, Salesforce, GitHub và SharePoint; đây là tính năng Enterprise Edition.

Onyx cũng có **user management**: quản lý users, roles, groups, invitations, deactivate/delete user, và gán quyền truy cập vào connectors, document sets, agents theo group. Hệ role của họ không chỉ có admin và user mà còn có cả **Curator** và **Global Curator** để giao quyền quản trị một phần. Groups còn có thể gán **token rate limits** để kiểm soát mức dùng model.

Ở lớp vận hành, Onyx có **query history**, **usage statistics**, feedback tracking, và export dữ liệu phân tích; docs nói đây là analytics để hiểu người dùng đang tương tác thế nào và theo dõi usage trong toàn tổ chức. Enterprise Edition còn thêm custom analytics provider, curator role, permission sync connectors, whitelabeling, enterprise APIs và priority support.

4) Model nào đang có và chi phí

Onyx đi theo hướng **nền tảng mở**. Admin có thể cấu hình Onyx để làm việc với **bất kỳ AI provider và model nào**. Onyx hỗ trợ cả cloud providers lẫn self-hosted providers; ví dụ OpenAI, Anthropic, Azure OpenAI, Bedrock, Google AI, OpenRouter, và các local/open-weight setup như **Ollama** hay **LM Studio**. Nếu provider chưa có sẵn, bạn còn có thể thêm **custom inference provider** miễn endpoint tương thích OpenAI API.

Từ v2.6.0, Onyx thêm cơ chế **dynamic model management**: tự lấy metadata model mới từ provider, tự làm hiện model mới, tự ẩn model deprecated, và đỡ phải redeploy chỉ để cập nhật danh sách model. Docs cũng cho phép admin chọn model nào được hiển thị cho người dùng, đặt default model, và cả fast model cho các tác vụ hậu trường như query expansion hay chat naming.

Về giá, Onyx tách thành **chi phí nền tảng** và **chi phí model/provider**. Trang pricing hiện ghi **Business từ 20 USD/user/tháng** khi thanh toán năm, **Enterprise** báo giá riêng, còn docs

Commented [HN3]: Đây là cách để các công cụ AI gọi vào knowledge base của Onyx qua chuẩn MCP (Model Context Protocol). Tức là không cần ngồi trong giao diện Onyx, những công cụ đó có thể hỏi Onyx để search tài liệu công ty, search web, hoặc lấy nội dung đầy đủ từ URL.

Commented [HN4]: Connectors là các đầu nối giữa Onyx và nguồn dữ liệu gốc của công ty. Ví dụ: nối với Google Drive để lấy file, nối với GitHub để lấy code/docs.

Commented [HN5]: Curator = quản một vài group cụ thể
Global Curator = quản mọi group mà mình nằm trong đó.

deployment ghi rõ có **self-host open-source miễn phí**, **Onyx Cloud**, và **self-host Enterprise Edition**. Onyx Cloud có **free trial 2 tuần**, không cần thẻ.

Nếu dùng Onyx theo kiểu **BYO provider** thì bạn còn phải trả tiền cho model bạn nối vào, cho web search provider nếu bật web search, và nếu self-host thì còn có chi phí hạ tầng. Docs quickstart ghi mức tối thiểu là **4 vCPU, 10 GB RAM, 32 GB disk + khoảng 2.5 lần dung lượng dữ liệu đã index**; mức khuyến nghị là **8+ vCPU, 16+ GB RAM**. Nếu có khoảng 50 GB tài liệu, guide resourcing còn gợi ý ít nhất khoảng **14 CPU và 30 GB RAM tổng khả dụng**. Đây là lý do chi phí thật của Onyx phụ thuộc khá mạnh vào deployment, model mix và khối lượng dữ liệu.

Commented [HN6]: BYO provider = Bring Your Own provider

5) Bảo mật và dữ liệu.

Với **self-host**, docs security nói rõ **mọi xử lý dữ liệu diễn ra trong hạ tầng của bạn**, không có dữ liệu nhạy cảm nào rời mạng của bạn trừ những giao tiếp bạn chủ động cấu hình. Docs connectors cũng nói việc xử lý và lưu trữ documents cùng metadata đều diễn ra trong Onyx; mặc định phần lớn xử lý là local, dù bạn vẫn có thể bật provider bên ngoài nếu muốn. FAQ còn ghi rõ với self-hosted deployment, **đội Onyx không nhận dữ liệu của bạn**, và telemetry tổng hợp có thể tắt.

Với **Onyx Cloud**, FAQ ghi nền tảng dùng **AES-256-GCM** cho dữ liệu at rest và **TLS 1.3** cho dữ liệu in transit. Deployment overview còn nói Onyx Cloud **SOC 2 Type II** và **GDPR compliant**.

Về truy cập, Onyx hỗ trợ **basic auth**, Google OAuth, và SSO qua Google, Okta, Azure Entra ID với **OAuth, OIDC, SAML**. Pricing và Enterprise docs cũng nhấn mạnh các tính năng như encrypted secrets, RBAC, permission inheritance và SSO cho môi trường doanh nghiệp. Repo và site sản phẩm đồng thời nhấn mạnh việc Onyx có thể chạy **self-host** và **air-gapped**, tức hợp với những nơi cần data sovereignty cao.

Điểm cần nhớ là Onyx có bảo mật tốt **nếu cấu hình đúng**. Rủi ro lớn không nằm ở khẩu hiệu sản phẩm mà ở chỗ bạn cấu hình connector, quyền Public/Private/Auto Sync Permissions, và provider inference như thế nào. Chính docs của họ cũng cảnh báo điều này.

6) Điểm mạnh và điểm yếu.

Điểm mạnh nhất của Onyx là nó ghép được những mảnh mà doanh nghiệp thật sự cần, thay vì chỉ làm một ô chat đẹp: internal search, connectors, permissions, user/group management, analytics, multi-model, actions/MCP, self-host, API, desktop app, extension, bot, và cả local model path qua Ollama/LM Studio. Nó đặc biệt hợp với team muốn tránh vendor lock-in, muốn tự giữ dữ liệu, hoặc muốn bắt đầu bằng search/chat rồi nâng dần lên agents và workflow. Về giá niêm yết, Onyx cũng minh bạch hơn khá nhiều so với nhiều sản phẩm enterprise search khác: site của họ công khai mức **20 USD/user/tháng** cho Business và nhấn mạnh chuyện self-host/open-source ngay từ đầu.

Điểm yếu Onyx là một **platform** nhiều hơn là một app mua về là dùng. Nếu đi self-host, bạn phải nghĩ tới hạ tầng, indexing, connector auth, phân quyền, provider bills, search quality, migration, và vận hành lâu dài. Ngay cả Deep Research cũng có thể đắt hơn inference thường rất nhiều; còn nhiều tính năng enterprise như analytics, permission sync, curator role hay SSO thì nằm ở paid/enterprise path. Thêm nữa, một số claim về chất lượng trả lời và benchmark là do chính Onyx công bố, nên nên xem như tín hiệu tham khảo tốt chứ không nên coi là kiểm chứng độc lập tuyệt đối. Phần này là đánh giá của mình dựa trên docs pricing, deployment, changelog, và phần benchmark trên site của họ.

7) Kiến trúc tổng thể của Onyx (<https://github.com/onyx-dot-app/onyx>)

Repo root cho thấy Onyx không phải một app web đơn giản mà là một hệ nhiều lớp: có **backend, web, desktop, widget, extensions/chrome, deployment, docs, examples, cli**. Điều này cho thấy Onyx là một “AI workplace platform”, không chỉ là một chatbot. Repo README cũng tự mô tả nó là self-hostable chat UI với nhiều capability, còn root tree cho thấy các bề mặt triển khai và client khác nhau đúng là có trong mã nguồn.

README của repo xác nhận Onyx “works with all LLMs ... and self-hosted LLMs”. Trong repo tree, phần core nằm chủ yếu ở backend, và cũng đã thấy có module llm, secondary_llm_flows, configs, tools, prompts.

Backend của họ có các module agents, tools, onyxbot, secondary_llm_flows, server, prompts. Chỉ nhìn layout thôi đã thấy agent/action không phải phần chấp vá ở UI, mà có backend organization riêng.